

Rapport Phase 3

Pourquoi l'agriculture, et plus
particulièrement l'agriculture biologique,
est en rémission ces dernières années ?

Réalisé par :

Simon Jehenne-Cousty

Léa Fargeot

Victoria Tandamba

Lucas Gelgon



Quoique la France reste la première puissance agricole de l'Union européenne, totalisant 17% de sa production, l'agriculture en France est en repli depuis plusieurs années. En effet, la France métropolitaine compte près de 390 000 exploitations agricoles en 2020, soit 100 000 de moins qu'en 2010. Cela représente une baisse moyenne des exploitations de 2.3% par an, d'après l'INSEE¹. L'agriculture biologique, quant à elle, observe une diminution de 1.9% en 2023².

Notre projet vise à observer l'évolution des Surfaces Agricoles Utilisées (SAU), de la production et des rendements depuis 2010 jusqu'à 2024, et chercher des raisons qui pourraient expliquer ces variations. Ce thème étant vaste, nous avons orienté nos recherches lors de la phase 1 vers l'exploration des facteurs d'influence au développement de l'agriculture, au travers de l'étude des performances agronomiques de l'agriculture conventionnelle et biologique, de l'effet du climat sur les cultures, ainsi que l'impact des politiques publiques sur l'engagement des exploitants dans le bio, en France.

Cependant, par manque de données, et à la suite de la réunion de conclusion de la phase 1, l'angle s'intéressant à l'impact des politiques a été retiré. Nous rappelons également que nous concentrons notre étude sur les parcelles agricoles. L'élevage, ou les apiculteurs sans surface par exemple, sont donc exclus. Nos jeux de données sont mis à l'échelle géographique du département pour le plus petit, une étude par commune nous semblant trop précise pour un gain d'information plutôt minime. De plus, dans une optique de consommation locale, seule la France Métropolitaine (Corse incluse) fait l'objet de notre étude.

Lors de la phase 2, nous avons établi les DFM et les dictionnaires de données de chaque fait. Ces derniers, de même que le raffinement de la *workload*, se trouvent en annexe, à la fin de ce rapport.

¹ « Transformations de l'agriculture et des consommations alimentaires » - INSEE
<https://www.insee.fr/fr/statistiques/7728861?sommaire=7728903#graphique-figure1>

² « Les chiffres de l'Agriculture Biologique en Nouvelle-Aquitaine pour 2023 et les tendances pour 2024 » - DRAAF Nouvelle-Aquitaine.
<https://draaf.nouvelle-aquitaine.agriculture.gouv.fr/les-chiffres-de-l-agriculture-biologique-en-nouvelle-aquitaine-pour-2023-et-les-a3538.html>

Table des Matières

I.	Rappel des besoins.....	6
1)	Comprendre l'évolution des performances agronomiques de l'agriculture en France.	6
2)	Comprendre la progression de l'agriculture biologique en France.....	6
3)	Comprendre l'impact d'évènements climatiques sur la production agricole en France.	6
II.	Rappel des DFM	7
III.	Déroulement de la phase 3	8
IV.	Schémas logiques.....	10
V.	Data Warehouse Architecture	11
1)	Architecture globale	11
2)	Master Job	12
VI.	Data Profiling et Transformations (ETL)	13
1)	Jeu de données sur l'agriculture globale en France (ETL JD 1).....	13
2)	Jeu de données sur l'agriculture bio en France (ETL JD 2)	17
3)	Historique détaillé des surfaces par département BIO (ETL JD 3)	19
4)	Professionnels engagés en BIO (ETL JD 4).....	21
5)	Données climatologiques (ETL JD 5)	22
6)	Jointure des jeux de données et master job.....	24
	Jeu n°1 et jeu n°2.....	24
	Jeu n°3 et jeu n°4.....	24
	Master Job	24
VII.	Entrepôt de données	25
VIII.	Conclusion	25
IX.	Annexes.....	26
	Annexe 1 : Mesure des performances agronomiques d'une culture (Fait n°1)	27
	Annexe 2 : Mesure des surfaces biologiques agricoles (Fait n°2)	29
	Annexe 3 : Mesure d'un évènement climatique (Fait n°3)	31
	Annexe 4 : Raffinement workload.....	32

Table des Tableaux

Tableau 1 : Analyse des attributs du jeu de données n°1.....	15
Tableau 2 : Analyse globale du jeu de données n°2	17
Tableau 3 : Analyse des chaînes de caractères du jeu de données n°3.....	19
Tableau 4 : Analyse des valeurs numériques du jeu de données n°3.....	19
Tableau 5 : Analyse des valeurs des colonnes utiles du jeu de données n°4	21
Tableau 6 : Analyse des valeurs numériques du jeu de données n°5.....	22
Tableau 7 : Analyse des chaînes de caractères du jeu de données n°5.....	22
Tableau 8 : Dictionnaire de données du Fait n°1	27
Tableau 9 : Dictionnaire de données du Fait n°2	29
Tableau 10 : Dictionnaire de données du Fait n°3.....	31

Table des Illustrations

Figure 1 : Schéma du Fait 3.....	7
Figure 2 : Schéma du Fait 2.....	7
Figure 3 : Schéma du Fait 1.....	7
Figure 4 : Diagrammes de GANTT Phase 3	9
Figure 5 : Schéma en constellation.....	10
Figure 6 : Schéma global de l'architecture	11
Figure 7 : Schéma du MASTER JOB.....	12
Figure 8 : Illustration de l'opération Unpivot.....	13
Figure 9 : Schéma de l'enchaînement des workflows KNIME	24
Figure 10 : Carte des zones climatiques en France.....	28

I. Rappel des besoins

1) Comprendre l'évolution des performances agronomiques de l'agriculture en France.

- Évolution de la surface par groupe de culture par an en France
- Évolution du rendement par groupe de culture par an en France
- Évolution de la production par groupe de culture par an en France
- Le rendement moyen de chaque groupe de culture ces 5 dernières années
- Les trois cultures de chacun de ces groupes (dernier besoin) avec les meilleurs rendements.
- Les départements les plus productifs en moyenne sur toute la période d'étude
- Comparaison de l'évolution de la surface agricole biologique par rapport à la surface agricole conventionnelle par année

Les jeux de données associés à cette partie sont le [1](#) et le [2](#).

2) Comprendre la progression de l'agriculture biologique en France.

- Évolution du nombre de nouvelles exploitations par an en France
- Quels sont les départements les plus dynamiques (avec le plus de surface de conversion en bio) sur un an.
- Au contraire, quelle part de surface bio retourne en conventionnel ou est abandonnée en France chaque année ?
- Quels sont alors les départements les plus en difficultés (les départements avec le plus de surface abandonnée) sur toute la période d'étude ?

Les jeux de données associés à cette partie sont le [3](#) et le [4](#).

3) Comprendre l'impact d'évènements climatiques sur la production agricole en France.

- Évolution de la production moyenne par groupe de culture par an en France (déjà présent dans l'étude de l'évolution des performances agronomiques, on s'en ressert).
- Évolution du nombre d'alertes sécheresse par an en France.
- Évolution du nombre d'alertes gel par an en France.
- Évolution du nombre d'alertes inondation par an en France.
- Évènements climatiques (sécheresse/gel/inondation) par département sur un an.

Les jeux de données associés à cette partie sont le [1](#) et le [5](#).

II. Rappel des DFM

La Mesure de la surface et des performances agronomiques (production, rendement) d'une culture sur un département sur une année




Figure 3 : Schéma du Fait 1

La mesure d'une surface sur un département et une année donnée




Figure 2 : Schéma du Fait 2

Un évènement climatique sur un département et une année donnée




Figure 1 : Schéma du Fait 3

III. Déroulement de la phase 3

Lors de cette phase, nous avons commencé par corriger les éléments pris en note lors de la réunion de fin de la phase précédente, à savoir les lignes manquantes des dictionnaires de données, et l'harmonisation des DFM également modifiés suites aux suggestions.

Ensuite, nous avons conçu le schéma en constellation de nos faits, effectué un profiling approfondi des jeux de données et un gros travail de fusion des fichiers csv pour les données météorologiques. Puis, nous avons conçu l'architecture de notre entrepôt, ainsi que le *master job*. Enfin, nous avons appliqué les transformations nécessaires sur les données, dans l'ETL, avant de créer et remplir notre entrepôt.

Durant cette phase, comme les précédentes, nous avons utilisé Discord afin de communiquer et organiser nos réunions. Contrairement aux phases 1 et 2, la phase 3 a nécessité un plus grand échange de fichiers et d'informations, c'est pourquoi nous avons également créé un GitHub.

Le chef de projet pour cette phase est Léa Fargeot.

Ci-dessous, quatre diagrammes de GANTT présentent le temps de travail de chaque membre du groupe, pour chaque tâche, avec le nombre de jours sur lesquels elles se sont étalées, et le nombre d'heures total passées sur la phase 3.

Figure 4 : Diagrammes de GANTT Phase 3



IV. Schémas logiques

La première étape a été de créer la constellation de notre entrepôt de données. Nous avons choisi d'utiliser des schémas en flocon de neige, dont nous avons ensuite réduit les tables de dimension dégénérées, pour arriver au schéma logique suivant.




Figure 5 : Schéma en constellation

V. Data Warehouse Architecture

1) Architecture globale




Figure 6 : Schéma global de l'architecture

2) Master Job




Figure 7 : Schéma du MASTER JOB

Prétraitement

- 1 - Voir partie transformation : 1) Jeu de données sur l'agriculture globale en France
- 2 - Voir partie transformation : 2) Jeu de données sur l'agriculture bio en France
- 3 - Voir partie transformation : 3) Historique détaillé des surfaces par département BIO
- 4 - Voir partie transformation : 4) Professionnels engagés en BIO
- 5 - Voir partie transformation : 5) Données climatologiques

JOIN

- 6 - Join du jeu de données agriculture globale France avec le jeu données Agriculture bio sur la culture, l'année et le codedepartement et avec le jeu de données sur les zones climatiques sur le codedepartement pour pouvoir récupérer la zone climatique et la surface bio
- 7 - Join du jeu de données Historique des surfaces bio par départements avec le jeu de données Professionnels engagés en bio sur l'année et le codedepartement et avec le jeu de données sur les zones climatiques pour pouvoir récupérer le nombre de nouveaux exploitants et la zone climatique
- 8 - Join du jeu de données climat avec le jeu de données sur les zone climatique sur le codedepartement pour pouvoir récupérer la zone climatique et la région

Aggrégation

- 9 - Tous les jeux de données sont aux granularités de base année et département

VI. Data Profiling et Transformations (ETL)

Lors du profiling de nos jeux de données, nous avons vérifié s'il y avait des valeurs manquantes, erronées, le format des données, tant des chaînes de caractères que des valeurs numériques. Chaque membre, qui s'est vu attribuer un à deux jeux, a ensuite utilisé le logiciel qui lui convenait le mieux, afin d'effectuer ces analyses.

Par ailleurs, les *workflows* KNIME joints à ce rapport détaillent précisément la technique de transformation avec des zones et des commentaires, c'est pourquoi lors de l'énumération des transformations à effectuer, déduites du profiling et pour chaque jeu de données, nous ne précisons que le nœud utilisé pour la réaliser (sauf cas particulier). Elles sont données dans l'ordre de leur exécution dans le *workflow*.

1) Jeu de données sur l'agriculture globale en France (ETL JD 1)

Le profiling et les transformations de ce jeu de données, se sont effectuées en trois grandes étapes.

Étape n°1 : Extraction des données via une rotation

Le logiciel KNIME a été utilisé pour effectuer rotation des données. En effet, ce jeu de données était un fichier Excel contenant plusieurs feuilles, chacune correspondant à un groupe de cultures. Chacune contient les attributs LIB_DEP (le département), LIB_REG2 (le nom de la région), LIB_SAA (le nom de la culture), REND (le rendement), SURF (la surface agricole) et PROD (la production).

Le problème, c'est que les attributs REND (le rendement), SURF (la surface agricole) et PROD (la production) étaient autant de colonnes qu'il y avait d'années. C'est-à-dire : une colonne REND_2010, une colonne REND_2011, un autre PROD_2015 etc. L'objectif premier a donc été de pivoter ces colonnes, pour n'obtenir à la fin que nos trois attributs SURF, PROD et REND, avec une ligne par année.

Pour ce faire, nous avons :

- Regroupé les colonnes de même genre (tous les REND, tous les PROD...) qui sont à pivoter, en une seule colonne, à l'aide du nœud *Unpivot*.

Par exemple, les colonnes de SURF_2010 à SURF_2024 ont été regroupées en une colonne nommée ColumnNames, avec les valeurs associées dans la colonne ColumnValues, de même pour PROD et REND.



#	RowID	RowIDs	ColumnNames	ColumnValues	LIB_REG2	LIB_DEP	LIB_SAA
345	Row34	Row9	SURF_2013	2	11 - Île-de-France	077 - Seine-et-Marne	10 - Mirabelle
390	Row38	Row10	SURF_2013	3	11 - Île-de-France	077 - Seine-et-Marne	11 - Reine-claude
435	Row43	Row11	SURF_2013	2	11 - Île-de-France	077 - Seine-et-Marne	12 - Quetsche

Figure 8 : Illustration de l'opération Unpivot

- Créé la colonne annee, grâce aux valeurs de la colonne ColumnNames, qui contient maintenant les valeurs SURF, REND, PROD.

→ *Noeud Cell Splitter* (*SURF_2013* devient SURF dans ColumnNames, et 2013 dans annee)

- Effectué le pivot de la colonne ColumnNames, ce qui a créé les trois colonnes rend, surf, et prod.

→ *Noeud Pivot*

- Renommé les colonnes → *Noeud Column Renamer*

Nouveaux noms :

LIB_DEP -> departement

LIB_SAA -> culture

LIB_REG2 -> region

SURF -> surface_totale

REND -> rendement

PROD -> production

- Séparé le libellé et le code de chaque département, région et culture.

(Par exemple, 077 - *Seine-et-Marne* devient 77 dans Code_departement et Seine-et-Marne dans Departement)

→ *Noeud Cell Splitter*

→ *Noeud String Manipulation*

- Enfin, nous avons regroupé tous les onglets en un seul fichier, afin de pouvoir faire un profiling plus efficient de ce jeu de données. Pour ce faire, nous avons ajouté la colonne Groupe_culture, qui contient le nom de chaque groupe de culture. (Exemple : COP : pour les céréales, LEG : pour les légumes, etc).

En tant que processus global, dans Knime, nous avons créé une boucle qui lit chaque feuille de culture, effectue la rotation et ajoute le nom de la feuille en tant que groupe de culture.

Au final, nous avons un jeu de données avec les attributs suivants :

code_region	region	code_departement	departement	culture	Groupe_culture	ANNEE	SURFACE	PRODUCTION	RENDEMENT
-------------	--------	------------------	-------------	---------	----------------	-------	---------	------------	-----------

Étape n°2 : Profiling des données sur l'agriculture globale

Pour le profiling de ce jeu de données, nous avons utilisé le logiciel Datacleaner, et plus précisément les nœuds d'analyse *String Analyser*, *DateTime Analyser* et *Number Analyser*. Cette analyse est résumée dans le tableau suivant :

Tableau 1 : Analyse des attributs du jeu de données n°1

	annee	code_departement	departement	code_region	region	culture	production	rendement	surface_totale
Row count	316492	316492	316492	316492	316492	316492	316492	316492	316492
Null count	0	0	0	0	0	0	0	145963	1500
Highest Value	2024	975	/	975	/	/	64820000	5966	438344
Lowest Value	2010	1	/	1	/	/	0	0	0
Mean	/	/	/	/	/	/	298 803,553	181,868	4 218,629

Par ailleurs, KNIME nous a permis de comprendre pourquoi certaines valeurs sont manquantes, notamment le nœud *Row Filter*.

De très longues valeurs sur la colonne cultures d'observer la présence de lignes de totaux sur les cultures, dont la cohérence était assez douteuse, nous avons donc retiré ces lignes.

De plus, la culture « PAILLES » présente des valeurs manquantes, notamment dans les champs surface_totale et rendement.

La paille étant une céréale non cultivée, le fait qu'il y ait des valeurs manquantes au niveau de la surface et donc du rendement (qui pour rappel, est le ratio de la production divisée par la surface) est justifié. Notre étude se portant que sur les cultures cultivées, nous avons filtré ces lignes, ainsi que d'autres cas similaires, qui ne rentraient pas dans le cadre de notre étude, tels que « Dessus de plants de pommes de terre », « Houblon non en production », ou encore « Surfaces cultures sucre détruites » ...

Certains de ces éléments auraient éventuellement pu être utiles si l'on s'intéressait à l'élevage (notamment la paille).

Étape n°3 : Transformations résultantes de l'analyse, effectuées dans cet ordre avec KNIME :

- Suppression des régions d'outre-mer pour rester cohérent dans le périmètre géographique de notre analyse.
 - *Noeud String Manipulation*
 - *Nœud Row Filter*

- Suppression des totaux des cultures afin d'éviter de compter deux fois, ce qui fausserait les sommes ou moyennes sur la production, la surface totale, et le rendement.
 - *Nœud Row Filter*
 - *Nœud Rule_Based Row Filter*

- Suppression des lignes contenant des valeurs manquantes sur le rendement et la surface totale, comme la culture « PAILLES », et suppression des éléments qui ne sont pas tout à fait des cultures, et qui ne sont pas dans l'analyse de nos besoins.
 - *Noeud Row Filter*

- Ajout d'une colonne ID_culture pour établir une liaison avec la source de données surface bio par culture (jeu de données n°2).
 - *Noeud Rule Engine*

2) Jeu de données sur l'agriculture bio en France (ETL JD 2)

Pour ce jeu de données, l'utilisation de *DataCleaner*, notamment avec les outils *Completeness Analyzer*, *Number Analyzer* et *String Analyzer*, a permis de vérifier qu'il n'y avait ni valeurs nulles ni outliers. Les données sont donc globalement de bonne qualité.

Le *String Analyzer* et le *Number Analyzer* nous ont permis de créer le tableau résumé ci-dessous :

Tableau 2 : Analyse globale du jeu de données n°2

	annee	coderegion	region	code departement	Groupe_production	production	surfbio
Row count	120554	120554	120554	120554	120554	120554	120554
Null count	0	0	0	0	0	0	0
Highest Value	2024	94	/	999	/	/	123460
Lowest Value	2008	1	/	1	/	/	0
Sum	/	/	/	/	/	/	29 142 681
Mean	2017	/	/	/	/	/	241,74

Cependant, les modules Character Set Distribution et Pattern Finder ont révélé plusieurs problèmes, notamment au niveau du format des données (Latin, non ASCII et Latin, ASCII), il y a aussi de l'harmonisation des données au niveau du groupe_production et enfin certaines lignes sont à supprimer pour ne garder que ce dont on a besoin (France métropolitaine, Corse comprise).

Transformations résultantes de l'analyse, effectuées dans cet ordre avec KNIME :

Importation

- Importation des données sources et renommage des colonnes afin d'obtenir une structure homogène pour la suite du traitement.
 - *Nœud CSV Reader*
 - *Nœud Column Renamer* (renommage des colonnes en *culture* et *groupe_culture*)

Harmonisation

- Les cultures et les groupes de cultures présentent des différences de dénomination selon les jeux de données. Une harmonisation est donc réalisée pour assurer la correspondance avec le premier jeu de données de référence.
 - *Nœud Rule Engine* (harmonisation des cultures)
 - *Nœud Rule Engine* (harmonisation des groupes de cultures)

Filtrage

- Conservation uniquement des groupes de cultures pertinents pour l'étude et suppression des doublons créés lors de l'étape d'harmonisation.
 - *Nœud Row Filter* (filtrage pour garder les bons groupes de cultures)
 - *Nœud Row Filter* (suppression des doublons issus de l'harmonisation)

Finalisation

- Création et mise en forme des dernières variables nécessaires, puis exportation du jeu de données final.
 - *Nœud Rule Engine* (création d'un identifiant *ID_culture* pour les jointures)
 - *Nœud String Manipulation* (création d'une colonne de longueur *codedep* pour filtrer les départements Outre-Mer)
 - *Nœud Row Filter* (filtrage pour retirer les départements « INCONNU » et ceux d'Ostre-Mer)
 - *Nœud Column Filter* (conservation uniquement des colonnes pertinentes (constellation) pour faire la jointure avec le jeu de données 1)
 - *Nœud Column Renamer* (renommage de la colonne *codedepartement*)
 - *Nœud Column Resorter* (mise en forme finale)
 - *Nœud Container Output* (Table) (extraction et sauvegarde du jeu final)

3) Historique détaillé des surfaces par département BIO (ETL JD 3)

Lors du profiling de ce jeu de données, nous avons utilisé le logiciel *DataCleaner*.

Dans un premier temps, le *character set distribution* nous a montré qu'une partie des noms de régions et départements sont en « Latin, non ASCII », tandis que la majorité est en « Latin ASCII ».

Le *String Analyzer*, nous a fourni une vision d'ensemble pour ces deux attributs :

Tableau 3 : Analyse des chaînes de caractères du jeu de données n°3

	departement	region
Row count	1712	1712
Null count	0	0
Blank count	0	0
Max char	26	23
Min char	5	3

Le *Number Analyzer*, nous fournit une vision d'ensemble des valeurs numériques. Parmi ces dernières, nous retrouvons l'année, les codes région et département, le nombre d'exploitants, ainsi que les surfaces (nous n'en mettons que 3, les autres étant construites exactement pareils, n'apportant pas d'information supplémentaire). Dans le tableau suivant, des éléments comme les moyennes ou les sommes n'ont aucun sens dans le cadre de certains attributs, ils seront donc marqués «/» :

Tableau 4 : Analyse des valeurs numériques du jeu de données n°3

	annee	coderegion	code departement	nb_exp	surfab	surfc1	surfbio
Row count	1712	1712	1712	1712	1712	1712	1712
Null count	0	11	0	0	0	0	0
Highest Value	2024	94	999	2045	100 514	18799	121198
Lowest Value	2008	1	1	1	0	0	0
Sum	/	/	/	595 149	22 713 446	2 697 598	28 419 340
Mean	2016	/	/	347,634	13 267,2	1 575,7	16 600,082

Le *Pattern Finder*, nous permet de nous assurer que les noms de départements et de régions sont corrects dans leur forme (pas de pattern particulier, les noms suivent tous une norme Aaaa, avec au plus 10 patterns différents). Les seules variations, sont dans la présence d'espaces/ de tirets... Néanmoins, cet analyseur nous montre la présence d'une valeur « INCONNU ».

Avec le *Completeness Analyzer*, nous observons que onze lignes comportent en effet les valeurs « INCONNU » pour les noms de département et de région. Ainsi que les valeurs 999 et NA pour le code département et le code région. Des valeurs nulles que l'on retrouve dans le tableau précédent.

Nous avons également étudié la distribution des valeurs pour les départements, les régions et les années, nous donnant une vue globale des éléments et leur répartition. Cela nous a permis de constater que d'une année sur l'autre on retrouve chaque département (et donc chaque région). Les petites différences (entre 97 et 102 départements par années) s'expliquent tout simplement par le fait que, ces années-là, aucune surface bio n'a été recensée par l'Agence Bio.

Transformations résultantes de l'analyse, effectuées dans cet ordre avec Knime :

- Uniformisation de l'encodage en UTF-8
→ *Næud CSV Reader*
- Le type des attributs n'est pas correct : les valeurs numériques sont actuellement des chaînes de caractères, il va donc falloir les transformer en *float*
→ *Næud CSV Reader*
- Onze lignes comportent une localisation inconnue, nous allons donc nous séparer de celles-ci (Département n°999, nom « INCONNU »)
→ *Næud String Replacer*
- Pour les années, notre période d'étude commence en 2010, il faut donc retirer les années précédentes
→ *Næud Row Filter*
- Dans la mesure où nous ne nous intéressons pas aux départements Outre-Mer, nous devons retirer les lignes correspondantes
→ *Næud Row Filter*
- Afin de simplifier les données, et obtenir par la suite, des visualisations plus claires, nous allons arrondir les mesures de surface au millième. La plupart sont déjà entre le dixième et le millième en termes de précision, c'est pourquoi arrondir celles qui vont jusqu'au cent millième, nous semble utile et sans perte d'information
→ *Næud Number Rounder*
- Enfin, il va falloir créer l'attribut *surface_abandonnee*. Les valeurs de cet attribut sont calculées en faisant la soustraction, d'une année sur l'autre, de la surface totale bio pour un département donné. (L'année 2010, qui est la première de la période d'étude, aura donc une valeur à 0, et les valeurs qui ne sont pas négatives seront mises à 0, puisqu'il n'y aura pas de surface abandonnée)
→ *Næud Sorter* (pour regrouper les départements puis les années),
→ *Næud Lag Column* (pour récupérer la valeur de surface bio de l'année précédente),
→ *Næud Math Formula* (pour calculer la surface abandonnée dans un département, d'une année sur l'autre),
→ *Næud Missing Value* (pour remplacer les missing values (pour 2010) par 0)

4) Professionnels engagés en BIO (ETL JD 4)

Ce jeu de données recense les opérateurs engagés en agriculture biologique en France. Nous sommes intéressés par les colonnes code postal, date d'engagement et activités. Le profiling a été effectué avec le logiciel KNIME.

Le jeu est propre en terme de qualité de données sur les colonnes mentionnées ci-avant, et sur la période d'étude (de 2010 à 2024), il n'y a donc pas de préparation particulière de ce point de vue-là.

Il reste alors à transformer et extraire ce dont nous avons besoin. La colonne code postal nous donne le département, quant à la date, elle nous fournit l'année. Nous ne nous intéressons, par ailleurs, qu'uniquement aux lignes de producteur. C'est-à-dire les lignes contenant « Production » dans la colonne Activité. Le tableau ci-dessous récapitule les informations intéressantes sur les données :

Tableau 5 : Analyse des valeurs des colonnes utiles du jeu de données n°4

	Date	Code_postal
Row Count	88343	88343
Null Count	0	0
Highest Value	31/12/2024	97680
Lowest Value	01/01/2010	1000

Transformations résultantes de l'analyse, effectuées dans cet ordre avec Knime :

- Uniformisation de l'encodage en UTF-8
→ *Næud CSV Reader*
- Extraire uniquement les lignes contenant « Production » dans la colonne Activities
→ *Næud Row Filter*
- Ajouter un "0" pour les codes postaux à 4 chiffres (pour les départements de 1 à 9) et extraire le numéro du département (avec un 0, le cas échéant)
→ *Næud Expression*
- Transformer la date (qui est un String) en type Date et extraire l'année
→ *Næud String To DateTime*
→ *Næud Date&Time Part Extractor*
- Garder uniquement les lignes de la période d'étude, entre 2010 et 2024
→ *Næud Row Filter*
- Enfin, il va falloir créer l'attribut *nb_nouveaux_exploitants*. Pour cela, on va agréger les données par département et par année, et compter le nombre de lignes
→ *Næud Column Combiner* (pour créer une colonne temporaire departement-année sur laquelle on va faire un groupe by)
→ *Næud Group By* (pour agréger par département et année (colonne temporaire) et faire un COUNT des lignes)

5) Données climatologiques (ETL JD 5)

Les données utilisées sont disponibles sous forme de plusieurs jeux de données. Un jeu de données par département pour la période de 1950 à 2023, puis un autre pour le même département, de 2024 à 2025. Cela donne une quantité de données astronomique (plus 80 millions de lignes). Il a donc fallu effectuer un premier travail de récupération des jeux, de fusion entre les années, puis finalement de filtrage préalable pour ne garder que les années à partir de 2010. Pour ce faire, nous avons implémenté un premier programme python de scraping qui récupère les fichiers (près de 200). Puis un second, qui va fusionner tous ces fichiers et ne garder que les lignes correspondant aux mesures effectuées après 2010 compris. Cela donne à la fin un jeu de données global de plus de 3Go.

Le profiling a été réalisé avec KNIME, sur les colonnes RR, TN, TX, TM, Annee, Code_dep (type numérique), date (type Date) et dep (type String).

Pour rappel, les colonnes RR, TN, TX et TM correspondent respectivement aux précipitations (en mm), et à la température minimale, maximale, et moyenne.

Suite au profiling, on remarque un certain nombre de valeurs nulles, dues à des mesures manquantes. Le jeu de données propose les relevés de plusieurs stations pour le même jour dans un département. C'est pourquoi, si une station n'a pas enregistré de mesure, une autre peut l'avoir fait, on ne perd donc pas forcément d'information dans le calcul des alertes. En effet, l'objectif est de créer une alerte pour chaque jour, si la température fluctue en fonction de certains critères (précisés dans le dictionnaire n°3 en annexe). Puis de compter le nombre d'alertes par année, pour un département. Sachant que l'on ne crée qu'une seule alerte par jour, si une seule station a enregistré une mesure génératrice d'alerte, le jour compte une alerte. De cette manière, ces lignes qui comportent des missing values peuvent être négligées. Nous avons pensé remplacer les valeurs manquantes par la moyenne mais pour le calcul des alertes cela ne nous a pas semblé des plus pertinent. De plus, nous avons déjà plus de dix-sept millions de lignes... Au final, nous avons donc fait le choix de filtrer ces lignes naturellement lors du calcul des alertes.

Tableau 6 : Analyse des valeurs numériques du jeu de données n°5

	RR	TN	TX	TM	Annee	Code_dep
Row count	17725160	17725160	17725160	17725160	17725160	17725160
Null count	301950	6188307	6189114	9263018	0	0
Highest Value	513	30.5	46	34.8	2025	95
Lowest Value	0	-31.1	-24.8	-27.9	2010	1
Mean	2.554	6.983	16.808	11.721	2016	/

Tableau 7 : Analyse des chaînes de caractères du jeu de données n°5

	date	dep
Row count	17725160	17725160
Null count	0	0
Blank count	0	0
Max date / char	11/10/2025	23
Min date / char	01/01/2010	3

Transformations résultantes de l'analyse effectuées dans cet ordre avec Knime :

- Uniformisation de l'encodage en UTF-8
→ *Næud CSV Reader*
- Harmonisation des départements pour la Corse
→ *Næud Rule Engine (numéros des départements)*
→ *Næud Rule Engine (noms des départements)*
- Filtre sur les attributs recherchés
→ *Næud Colum filter*
- Suppression des lignes de 2025
→ *Næud Row filter*
- Harmonisation des codes départements (par exemple 1 -> 01)
→ *Næud String manipulation multi-column*
- Création d'une colonne type d'alerte dont les valeurs dépendent des températures et précipitations
→ *Næud Rule Engine*
- Suppression de lignes inutiles
→ *Næud Row filter (lignes sans alertes)*
→ *Næud GroupBY (doublons liés aux stations)*
- Agrégation par département, année et type d'alerte + ajout du nombre d'alertes pour chacune des lignes
→ *Næud GroupBY*
- Gestion des lignes sans alerte
→ *Næud GroupBY (agrégation par département et année)*
→ *Næud ConstantValueColumn (ajout d'une colonne gel)*
→ *Næud ConstantValueColumn (ajout d'une colonne sécheresse)*
→ *Næud ConstantValueColumn (ajout d'une colonne inondation)*
→ *Næud Unpivot (rotation afin d'avoir une seule colonne type alerte)*
→ *Næud GroupBy (agrégation)*
→ *Næud Joiner (extraction des lignes sans alerte via un left joiner)*
→ *Næud Missing values (remplacement des valeurs de la colonne nbAlertes (ici null partout) par 0)*
→ *Næud Joiner (Ajout des lignes sans alertes, 73 lignes, aux données existantes)*
- Renommage et tri des colonnes
→ *Næud Columne renamer*
→ *Næud Columne resorter*

6) Jointure des jeux de données et master job

Jeu n°1 et jeu n°2

Suite aux transformations précédentes, une jointure entre les jeux de données n°1 et n°2, sur le code du département, l'année, et l'id culture, a permis la formation du Fait n°1, en ajoutant la surface bio, et le calcul de la surface conventionnelle.

Afin de réaliser cette jointure, nous avons créé un nouveau workflow, qui, à l'aide du nœud Call Workflow, appelle les deux workflows dont il a besoin. Les nœuds Container Table Input et Output permettent respectivement de récupérer et renvoyer une table de données à un nœud Call Workflow.

De cette manière, les CSV d'entrée sont centralisés dans le workflow appelant, et il n'est alors nécessaire d'exécuter que ce dernier pour créer la table du Fait n°1.

Jeu n°3 et jeu n°4

Suite aux transformations précédentes, une jointure entre les jeux de données n°3 et n°4, sur le code du département et l'année, a permis la formation du Fait n°2, en ajoutant le calcul du nombre de nouveaux exploitants.

Afin de réaliser cette jointure, nous avons créé un nouveau workflow, qui, à l'aide du nœud Call Workflow, appelle les deux workflows dont il a besoin, de la même manière que pour le Fait 1.

De plus, une jointure avec deux autres CSV que nous avons créé, contenant les zones climatiques, et les tranches d'années, a été réalisée.

Master Job

Aucune jointure n'a été à effectuer pour le fait n°3, qui correspond tout simplement au jeu de données n°5, mais un workflow l'appelant a tout de même été créé, dans un souci d'harmonisation, et dans le cas où une évolution future appellerait à faire une jointure dessus. Nous avons ensuite créé un neuvième workflow qui permet d'appeler les trois workflows des Faits en une seule exécution, et écrire leur résultat respectivement dans trois CSV différents.

Pour illustrer cette architecture, voici un schéma de l'enchaînement des différents workflows.




Figure 9 : Schéma de l'enchaînement des workflows KNIME

VII. Entrepôt de données

À l'issue de la transformation des données, nous avons un jeu de données pour chaque fait, comme modélisé dans les DFM. Il reste donc la création de l'entrepôt, puis l'insertion des données.

Pour ce faire, nous avons choisi d'utiliser SGBD PostgreSQL. Nous avons rédigé un script SQL qui crée les tables selon le schéma en constellation du projet.

Ensuite, nous avons créé un script python permettant de créer automatiquement des requêtes SQL INSERT INTO, ce qui nous a permis de remplir rapidement les dimensions « periode » et « zone_climatique ».

Puis, nous avons créé des tables temporaires pour chaque fait, et inséré les données grâce au même script python.

Enfin, nous avons inséré les données dans les tables de dimension restantes, et celles de fait, de la constellation, avant de supprimer les tables temporaires.

VIII. Conclusion

À l'issue de cette troisième phase, notre entrepôt de données est fonctionnel. Nous avons rencontré quelques difficultés lors des choix de transformation des données, et sur l'harmonisation des noms de cultures et groupes de culture, notamment, mais un travail de réflexion, aussi bien individuel que collectif, a permis de tous les résoudre.

IX. Annexes

La section annexes contient :

- Les dictionnaires de données de l'entrepôt, pour chaque fait
- Le raffinement de la *workload*.

Annexe 1 : Mesure des performances agronomiques d'une culture (Fait n°1)

Tableau 8 : Dictionnaire de données du Fait n°1

Nom Attribut	Type	Description	Valeurs possibles
culture	String	Le nom de la culture concernée par la mesure de la ligne.	Il y a 212 cultures différentes. Exemple : « 02 - Blé tendre de printemps »
groupe_culture	String	Chaque culture appartient à un groupe plus large. Ces groupes sont déterminés en fonction des types de cultures.	Il y a 6 groupes de cultures. Exemple : « Céréales, oléagineux et protéagineux »
region	String	La région concernée par la mesure de la ligne. Une région est composée de plusieurs départements.	Il y a 13 régions en France Métropolitaine (+ 5 d'Outre-Mer) Exemple : « 11 - Île-de-France »
departement	String	Le département concerné par la mesure de la ligne. Une culture peut être développée dans plusieurs départements.	Il y a 96 départements en France Métropolitaines. Exemple : « 077 - Seine-et-Marne »
zone_climatique	String	La France est divisée en trois grandes zones climatiques, selon la carte ci-après. Chaque département appartient à une seule d'entre-elles. - H1 (bleu) : zone dite « froide », avec des hivers longs. - H2 (vert) : zone dite « tempérée », avec des hivers modérés et des étés parfois chauds. - H3 (rouge) : zone dite « chaude », avec des hivers doux, et des étés très chauds.	Il y a 3 zones climatiques. Exemple : « H1 »
annee	Int	Année de la prise de la mesure de la culture pour cette ligne. Format : AAAA	Les années de 2010 à 2024. Exemple : 2010
tranche_annees	String	Tranche d'années consécutives comprises entre une année a et une année b incluses.	Il y a 3 valeurs possibles : 2010-2014, 2015-2019 et 2020-2024 Exemple : « 2010-2014 »
surface_totale	Float	Surface occupée par la culture dans un département, pour une seule année. Cette surface est mesurée en hectare (1 ha = 10000m ²)	Exemple : 55165
surface_conventionnelle	Float	Surface conventionnelle occupée par la culture dans un département, pour une seule année. Cette surface est mesurée en hectare (1 ha = 10000m ²) La surface conventionnelle est calculée grâce à la surface bio qui est récupérée dans le jeu de données « Agriculture bio en France » : $Surface_conventionnelle = Surface_totale - surface_bio$	Exemple : 8148,8
surface_bio	Float	Surface bio occupée par la culture dans un département, pour une seule année. Cette surface est mesurée en hectare (1 ha = 10000m ²) La surface bio est récupérée dans le jeu de données « Agriculture bio en France ».	Exemple : 166,5

production	Float	Production totale (bio + conventionnel) de la culture dans un département, pour une seule année. La production, qui est la quantité récoltée, est mesurée en quintal (1 quintal = 100Kg).	Exemple : 3720995
rendement	Float	Rendement (bio + conventionnel) de la culture dans un département, pour une seule année. Le rendement est le ratio de la <i>production/surface</i> , il se mesure donc en quintal par hectare. Il sera recalculé si un autre niveau de granularité est utilisé.	Exemple : 67,45

Figure 10 : Carte des zones climatiques en France



Annexe 2 : Mesure des surfaces biologiques agricoles (Fait n°2)

Tableau 9 : Dictionnaire de données du Fait n°2

Nom Attribut	Type	Description	Valeurs possibles
tranche_annees	String	Tranche d'années consécutives comprises entre une année <i>a</i> et une année <i>b</i> incluses.	Il y a 3 valeurs possibles : 2010-2014, 2015-2019 et 2020-2024 Exemple : « 2010-2014 »
annee	Int	Année de la prise de la mesure de la culture pour cette ligne. Format : AAAA	Les années de 2010 à 2024. Exemple : 2013
zone_climatique	String	La France est divisée en trois grandes zones climatiques. Chaque département appartient à une seule d'entre-elles. - H1 (bleu) : zone dite « froide », avec des hivers longs. - H2 (vert) : zone dite « tempérée », avec des hivers modérés et des étés parfois chauds. - H3 (rouge) : zone dite « chaude », avec des hivers doux, et des étés très chauds.	Il y a 3 zones climatiques. Exemple : « H1 »
region	String	La région concernée par la mesure de la ligne. Une région est composée de plusieurs départements.	Il y a 13 régions en France Métropolitaine. Exemple : « Pays de la Loire »
departement	String	Le département concerné par la mesure de la ligne. Une culture peut être développée dans plusieurs départements.	Il y a 96 départements en France Métropolitaines. Exemple : « Loire-Atlantique »
nb_nouveaux_exploitants	Int	Nombre d'exploitants s'étant convertis pour la première fois en agriculture biologique, l'année correspondante, dans le département correspondant à la ligne. On ne considère que le propriétaire de l'exploitation, c'est pourquoi <i>n</i> nouveaux exploitants = <i>n</i> nouvelles exploitations, ce qui fait le lien avec l'attribut « Nb_exploitations ». Un exploitant n'a qu'une seule date de conversion, il ne peut donc être comptabilisé qu'une seule fois en tant que nouveau sur toute la période d'étude. (* voir sous le tableau pour plus de détails)	Exemple : 6
surface_conversions	Float	Somme des surfaces des trois années en conversion biologique (C1, C2, C3). Cette mesure est en hectare (1 ha = 10000m²).	Exemple : 2456,155
surface_abandonnee	Float	Surface non reconduite en bio l'année suivante (ce qui implique qu'elle était bio l'année précédente). Cette mesure est en hectare (1 ha = 10000m²). (** voir sous le tableau pour plus de détails)	Exemple : 104,45

** Provenance de l'attribut « Nb_nouveaux_exploitants »*

Les valeurs de cet attribut sont calculées à partir du jeu de données sur les opérateurs bio (disponible en Annexe - 4). On récupère uniquement les opérateurs qui effectuent une activité de producteur, l'année que l'on extrait de leur date de conversion, le numéro du département déduit de leur code postal, et on compte le nombre d'opérateurs en fonction de ces trois éléments. Cela nous donne alors le nombre de nouveaux exploitants pour une année et un département.

*** Provenance de l'attribut « Surface_abandonnee »*

Les valeurs de cet attribut sont calculées en faisant la soustraction, d'une année sur l'autre, de la surface totale bio. L'année 2010, qui est la première de la période d'étude, a donc une valeur nulle.

Par exemple : Surface_BIO_Totale (de 2012) - Surface_BIO_Totale (de 2011)

Si le résultat n est négatif, il y a eu une surface de n hectares d'abandonnée. Sinon, la valeur est 0.

Annexe 3 : Mesure d'un évènement climatique (Fait n°3)

Tableau 10 : Dictionnaire de données du Fait n°3

Nom Attribut	Type	Description	Valeurs possibles
annee	Date	Année de la prise de la mesure de la culture pour cette ligne. Format : AAAA	Les années de 2010 à 2024. Exemple : 2013
tranche_annees	Date	Tranche d'années consécutives comprises entre une année <i>a</i> et une année <i>b</i> incluses.	Il y a 3 valeurs possibles : 2010-2014, 2015-2019 et 2020-2024 Exemple : « 2010-2014 »
zone_climatique	String	La France est divisée en trois grandes zones climatiques. Chaque département appartient à une seule d'entre-elles. - H1 (bleu) : zone dite « froide », avec des hivers longs. - H2 (vert) : zone dite « tempérée », avec des hivers modérés et des étés parfois chauds. - H3 (rouge) : zone dite « chaude », avec des hivers doux, et des étés très chauds.	Il y a 3 zones climatiques. Exemple : « H1 »
region	String	La région concernée par la mesure de l'évènement climatique. Une région est composée de plusieurs départements.	Il y a 13 régions en France Métropolitaine. Exemple : « Pays de la Loire »
departement	String	Le département concerné par la mesure de l'évènement climatique.	Il y a 96 départements en France Métropolitaine. Exemple : « Loire-Atlantique »
type_alerte	String	Il y a trois types d'alerte possibles : - « Sécheresse », si la température maximale est supérieure à 25°C (Météo-France) - « Gel », si la température minimale est inférieure ou égale à 0°C (Météo-France) - « Inondation », si le niveau des précipitations est supérieur à 40mm (Météo-France)	Exemple : « Gel »
nb_alertes	int	Nombre d'alertes (correspondantes au type d'alertes de la ligne) dans l'année	Exemple : 5

Annexe 4 : Raffinement workload

Pour des raisons de clarté, les faits sont abrégés en acronymes :

- MPAC : Mesure des performances agronomiques d'une culture
- MSAB : Mesure des surfaces agricoles bio
- MEC : Mesure d'un évènement climatique

Mesure des performances agronomiques d'une culture :

- Étude de l'évolution de la surface de chaque groupe de culture chaque année
 - MPAC[annee, groupe_culture].SUM_surface_totale
- Étude de l'évolution du rendement par groupe de culture chaque année
 - MPAC[annee, groupe_culture].ratio_rendement
- Étude de l'évolution de la production de chaque groupe de culture chaque année
 - MPAC[annee, groupe_culture].AVG_production
- Étude des meilleurs rendements par groupe de culture sur les cinq dernières années
 - MPAC[groupe_culture; tranche_annees = «2019-2024»].ratio_rendement
- Étude des départements les plus productifs sur toute la période d'étude
 - MPAC[departement].AVG_production
- Étude de l'évolution de la surface bio par années
 - MPAC[annee].SUM_surface_bio
- Étude de l'évolution de la surface agricole conventionnelle par années
 - MPAC[annee].SUM_surface_conventionnelle

Mesure des surfaces agricoles bio :

- Étude de l'évolution du nombre de nouveaux exploitants par an en France
 - MSAB[annee].SUM_nb_nouveaux_exploitants
- Étude des régions les plus dynamiques (avec le plus de surface de conversion) sur un an
 - MSAB[region; annee = n].SUM_surface_conversion
- Étude de la part de surface bio qui retourne au conventionnel ou est abandonnée en France chaque année
 - MSAB[annee].SUM_surface_abandonnee
- Étude des départements les plus en difficulté (avec le plus de surface abandonnée)
 - MSAB[departement].SUM_surface_abandonnee

Mesure d'un évènement climatique :

- Étude de l'évolution du nombre d'alertes sécheresse par an en France
 - MEC[annee; typeAlerte = « Sécheresse »].SUM_nb_alertes
- Étude de l'évolution du nombre d'alertes gel par an en France
 - MEC[annee; typeAlerte = « Gel »].SUM_nb_alertes
- Étude de l'évolution du nombre d'alertes inondation par an en France
 - MEC[annee; typeAlerte = « Inondation »].SUM_nb_alertes
- Étude de l'évolution du nombre d'alertes sécheresse par département sur une année
 - MEC[departement; typeAlerte = « Sécheresse »].SUM_nb_alertes
- Étude de l'évolution du nombre d'alertes gel par département sur une année
 - MEC[departement; typeAlerte = « Gel »].SUM_nb_alertes
- Étude de l'évolution du nombre d'alertes inondation par département sur une année
 - MEC[departement; typeAlerte = « Inondation »].SUM_nb_alertes